# EEG e Imaginación Motora para la Rehabilitación de Pacientes con Stroke
## Ingeniería de Características y Entrenamiento por Sujeto sobre el Dataset Cho2017

Anachuri, Mariel - Chungara, Clara Ines- Giolitto, Camila

***Diplomatura en Ciencia de Datos e Inteligencia Artificial Aplicadas a Investigación en Salud***
*Mentoría Propuesta 3 — Mentor: Bruno Zorzet*

---

**Resumen**

En este trabajo se desarrolló un pipeline de procesamiento de señales EEG y aprendizaje automático para clasificar dos tareas de imaginación motora (mano izquierda y mano derecha) utilizando la base de datos Cho2017. A partir de la señal EEG se realizó una etapa de ingeniería de características, transformando los registros originales en un conjunto de datos tabular mediante descriptores frecuenciales, temporales y espaciales. Sobre este conjunto de características se entrenaron modelos de Machine Learning bajo una estrategia *within-subject*, comparando Árbol de Decisión, Random Forest, SVM y CSP+LDA como modelo baseline. La evaluación permitió analizar el desempeño de los clasificadores y la influencia de la variabilidad individual asociada al fenómeno de *BCI Illiteracy*.

**Palabras Clave**

EEG, MI-BCI, Ingeniería de Características, Machine Learning, BCI Illiteracy

## I. INTRODUCCIÓN Y PROBLEMÁTICA

Las interfaces cerebro-computadora basadas en imaginación motora (*Motor Imagery Brain-Computer Interfaces*, MI-BCI) permiten decodificar la intención de movimiento de un usuario a partir de señales de electroencefalografía (EEG), constituyendo una herramienta de interés para aplicaciones de rehabilitación motora en pacientes con accidente cerebrovascular (*stroke*).

El despliegue de estas tecnologías enfrenta dos desafíos de alta complejidad:

1. Alta variabilidad inter-sujeto: Las señales EEG son inherentemente no estacionarias y presentan firmas espectrales y espaciales únicas para cada individuo, lo que impide el uso eficiente de modelos globales de clasificación.
2. El fenómeno de BCI Illiteracy (o Ineficiencia BCI): Se estima estadísticamente que un porcentaje significativo de usuarios (~20% en la literatura general) es incapaz de producir respuestas cerebrales lo suficientemente discriminativas o voluntarias como para operar un sistema BCI de forma confiable.

Para abordar esta problemática, este trabajo utiliza la base de datos Cho2017 (52 sujetos, ~200 ensayos por sujeto balanceados en dos clases), reduciendo el espacio de análisis a solo 3 canales críticos: C3, Cz y C4, remuestreados a 128 Hz .

El objetivo central de este proyecto es diseñar, implementar y evaluar críticamente un pipeline de procesamiento de señales e ingeniería de características multidominio, comparando algoritmos clásicos tabulares frente al estándar espacial de la industria (CSP+LDA) bajo un esquema realista de validación intra-sujeto (within-subject) que cuantifique el impacto del BCI Illiteracy.

## II. METODOLOGÍA

Se adoptó un enfoque within-subject (intra-sujeto) para mitigar la variabilidad interindividual del EEG. A partir de las señales preprocesadas, representadas como matrices de dimensiones ensayos × 3 canales (C3, Cz, C4) × tiempo, se ejecutaron las siguientes etapas:

1. Extracción y construcción del conjunto de características

La variable objetivo (intención motora) se codificó de forma binaria (0: mano izquierda, 1: mano derecha). Sobre cada ensayo se generaron 51 descriptores, agrupados en tres familias:

- Frecuenciales: potencia total (RMS) y potencia espectral en 6 bandas de frecuencia (4-8, 8-12, 12-16, 16-20, 20-24 y 28-30 Hz), vía método de Welch (Welch, 1967).
- Temporales y de complejidad: kurtosis, skewness, dimensión fractal de Katz (Katz, 1988), coeficientes autorregresivos (orden 2) y entropía de permutación (orden 3).
- Espaciales y de conectividad: correlación cruzada, coherencia espectral (MSC) y Phase Locking Value (PLV), entre C3-Cz, C4-Cz y C3-C4.

La consolidación sobre los 52 sujetos dio como resultado un dataset de 10.520 ensayos × 54 columnas (51 características + 3 columnas de metadatos: sujeto, etiqueta codificada y su versión legible).

2. Análisis exploratorio y prevención de data leakage

Se generaron gráficos de boxplot + stripplot por canal y por clase para evaluar el solapamiento entre distribuciones. Se determinó que la inspección visual univariada no alcanza para anticipar el rendimiento de un clasificador multivariado; para una conclusión válida se requieren pruebas de hipótesis formales (Shapiro-Wilk, seguido de test paramétrico o no paramétrico). Ninguna selección o transformación de características se aplicó antes del split, para evitar data leakage.

3. Pipeline de Machine Learning y evaluación

Para cada sujeto, los datos se dividieron con un split estratificado 80/20, reservando el test solo para la evaluación final. Dentro del 80% de entrenamiento se aplicó un objeto GridSearchCV acoplado a una validación cruzada estratificada de 5 particiones. El proceso de escalado de variables (StandardScaler), cuando correspondía, se encapsuló estrictamente dentro de un Pipeline de Scikit-Learn. Esto garantizó que los parámetros de normalización se estimaran e introdujeran únicamente con los datos de entrenamiento de cada pliegue, impidiendo que la información de validación o prueba sesgue el ajuste de los modelos.

Como cierre de este flujo, el pipeline entrenó y optimizo de forma independiente los cuatro modelos seleccionados para cada uno de los 52 sujetos. Al concluir esta etapa, se consolidó una matriz de rendimiento que contiene, por cada individuo, cuatro métricas de exactitud (accuracy) definitivas calculadas de manera exclusiva sobre sus propios conjuntos de prueba blindados.

4. Elección de Modelos y Criterios de Ajuste

- Justificación de Modelos: Se buscó cubrir el espectro metodológico completo para contrastar el paradigma de características hechas a mano (handcrafted features) contra un método que aprende su propia proyección espacial de los datos. Bajo esta premisa se eligieron: Árbol de Decisión (modelo base interpretable de baja complejidad),

Random Forest (ensamble robusto al ruido; Breiman, 2001), SVM (modelo de margen máximo con capacidad no lineal vía kernel; Cortes & Vapnik, 1995) y CSP + LDA (estándar de la industria en MI-BCI; Ramoser et al., 2000), este último ajustado directamente sobre la señal EEG cruda de los 3 canales espaciales y usado como baseline obligatorio.

- Ajuste de Hiperparámetros: Las configuraciones se optimizaron mediante la grilla de GridSearchCV, evaluando parámetros críticos como la profundidad y poda en árboles (max_depth, min_samples_leaf), la cantidad de estimadores en Random Forest, la regularización (C) junto al tipo de kernel en SVM, y el número de componentes espaciales en CSP. La selección final se basó estrictamente en la exactitud (accuracy) promedio obtenida en la validación cruzada.
- Balanceo de Clases: Dado que el diseño experimental de la base Cho2017 entrega clases naturalmente balanceadas (~50/50 entre ambas manos), se determinó omitir cualquier técnica de remuestreo.

5. Configuración del Filtro de BCI Illiteracy

Para distinguir el desempeño predictivo real del azar estadístico de forma rigurosa ante el tamaño finito de la muestra de prueba, se diseñó un filtro de exclusión basado en el modelado de la Distribución Binomial bajo la hipótesis nula ($H_0$) de un clasificador aleatorio puro.

Las decisiones teóricas que rigieron el filtro contemplaron una probabilidad teórica de acierto de $p = 0.5$ (debido al balance dicotómico de clases) y un nivel de significancia de $\alpha = 0.05$ para tolerar un margen de error máximo del 5%. Considerando el tamaño del conjunto de prueba, la distribución binomial estableció un mínimo matemático de 0.650 de accuracy para rechazar la hipótesis de azar y considerar "apto" a un sujeto. Este criterio oficial de corte se aplicó evaluando de forma estricta el rendimiento obtenido sobre el modelo baseline CSP+LDA.

## III. ANÁLISIS DE RESULTADOS Y DISCUSIÓN

1. Comparación Global de Modelos (52 Sujetos)

Los cuatro modelos superaron en promedio el nivel de azar teórico de 0.5 (donde 0.5 representa la probabilidad de acierto aleatorio puro en clasificación binaria). Las Máquinas de Vectores de Soporte (SVM) y Random Forest lideraron el desempeño predictivo transversal con valores de exactitud media de 0.677 y 0.665, seguidas por el Árbol de Decisión (0.619) y CSP+LDA (0.591) con el rendimiento más bajo del estudio. La alta dispersión observada en los desvíos estándar reflejó la marcada variabilidad intersujeto, lo que convalida la decisión metodológica de entrenar los modelos bajo el enfoque intra-sujeto.

El bajo desempeño general obtenido por CSP + LDA (0.591) contrasta con el rendimiento reportado habitualmente en la literatura clásica para este dataset. La explicación a este fenómeno puede radicar en la restricción del hardware implementada en este diseño experimental. El algoritmo CSP es un optimizador espacial que requiere una alta dimensionalidad (muchos electrodos, como los 64 del montaje original de Cho2017) para calcular matrices de covarianza cruzada robustas. Al reducir el espacio de análisis a solo 3 canales (C3, Cz, C4), CSP pierde prácticamente todos sus grados de libertad espaciales, volviéndose altamente sensible al ruido.

Por el contrario, los modelos tabulares demostraron que cuando el hardware limita la resolución espacial, la ingeniería de características multidominio logra compensar la pérdida de sensores físicos, encontrando fronteras de decisión no lineales complejas (como las de SVM con kernel RBF) que un extractor puramente espacial no detecta sobre señales crudas desnudas.

2. Filtro de BCI Illiteracy y Análisis de la Subpoblación Apta

Tomando el clasificador de referencia (CSP+LDA) como el baseline, solo 14 de los 52 sujetos (26.9%) calificaron como aptos al superar el umbral binomial de corte de 0.650, mientras que 38 sujetos (73.1%) quedaron por debajo del umbral bajo la condición de BCI Illiteracy.

El filtro estadístico no modificó los datos ni requirió el reentrenamiento de los clasificadores. En su lugar, se procedió a aislar las filas correspondientes a los 14 sujetos declarados aptos dentro de la tabla consolidada de resultados para evaluar el comportamiento del ecosistema de modelos bajo perfiles neurofisiológicos validados. Al calcular las métricas exclusivamente sobre este subgrupo purgado, se observó una mejora sistemática drástica de entre 12 y 16 puntos porcentuales en la exactitud media de todas las arquitecturas:

- Árbol de Decisión: Escala de 0.619 a 0.739 (+0.120).
- CSP + LDA (Baseline): Escala de 0.591 a 0.741 (+0.150).
- Support Vector Machine (SVM): Escala de 0.677 a 0.824 (+0.147).
- Random Forest: Escala de 0.665 a 0.821 (+0.156).

Este salto cuantitativo convalida estadísticamente que el filtro basado en la distribución binomial efectivamente segrega dos poblaciones con firmas bioeléctricas cualitativamente distintas. Al remover el ruido inducido por los sujetos incapaces de modular sus ritmos corticales, el rendimiento de todos los algoritmos se incrementó notablemente, incluyendo al propio CSP+LDA (+15 puntos), confirmando que cuando la firma fisiológica existe, el algoritmo espacial funciona aun con limitaciones de hardware.

Desde una perspectiva clínica, SVM (0.824) y Random Forest (0.821) rompieron la barrera crítica del 0.80 de exactitud media. En la ingeniería biomédica y la práctica, un accuracy superior a 0.80 se establece como el umbral operativo mínimo para considerar que una interfaz cerebro-computadora es funcional y usable por un paciente en rehabilitación post-stroke, permitiéndole controlar un software de neurorretroalimentación de manera fluida y sin experimentar frustración por falsos comandos.

3. Fortalezas, Limitaciones y Enfoques No Concretados

- Fortalezas: El blindaje absoluto contra el Data Leakage mediante el uso de pipelines encapsulados de Scikit-Learn garantizó una evaluación estadísticamente honesta. Asimismo, la superioridad de SVM y Random Forest sobre CSP+LDA demostró que cuando el hardware limita la resolución espacial (solo 3 canales), la ingeniería de características multidominio (potencia de Welch, complejidad de Katz, conectividad PLV/MSC) es la estrategia más robusta para rescatar patrones discriminativos de la intención motora.

- Limitaciones: El tamaño de la muestra por sujeto (~200 ensayos) resulta acotado al momento de entrenar modelos tradicionales bajo optimizaciones de grilla densa, induciendo riesgos latentes de sobreajuste en los límites inferiores de usuarios difíciles. Además, las subbandas de la PSD se fijaron de forma global uniforme, ignorando que la frecuencia central de los ritmos mu y beta varía fisiológicamente entre individuos (y más aún tras sufrir un stroke).
- Enfoques e Ideas No Concretados: Debido a restricciones de tiempo computacional y redefiniciones del alcance acordadas, quedaron fuera del entregable final la implementación de algoritmos de selección formal de variables (SelectKBest vía ANOVA, RFE o regularizaciones Lasso L1) para comprimir y optimizar las 51 características. De igual modo, no pudo concretarse la proyección gráfica no lineal del espacio masivo mediante algoritmos como t-SNE y UMAP, planteados originalmente para mapear visualmente la separación geométrica tridimensional entre la población apta y aquella con BCI Illiteracy.

## IV. CONCLUSIONES Y TRABAJO FUTURO

1. Conclusiones Generales

El presente trabajo demostró que la viabilidad de una Interfaz Cerebro-Computadora (MI-BCI) basada en Machine Learning tradicional depende de la neurofisiología individual del usuario. A través de la experimentación con múltiples algoritmos (Árboles de Decisión, Random Forest, SVM y la línea base espacial CSP+LDA), se comprobó que los modelos son capaces de extraer patrones discriminativos de la intención motora, pero su eficacia global se ve condicionada por la variabilidad intersujeto.

La integración de un umbral estadístico estricto transformó el enfoque analítico del proyecto: demostró que un modelo predictivo debe evaluar su capacidad de superar un límite de significancia frente al azar. Si bien los hallazgos revelaron una alta prevalencia de "BCI Illiteracy" en la población general bajo configuraciones de hardware reducidas, al aislar estadísticamente a los sujetos aptos, los clasificadores escalan sustancialmente su rendimiento predictivo, alcanzando precisiones aptas para entornos clínicos.

2. Trabajo Futuro y Enfoques Avanzados

Para mitigar las limitaciones encontradas y reducir la tasa de BCI Illiteracy, el paso natural a seguir es transicionar hacia arquitecturas de Aprendizaje Profundo (Deep Learning). Se propone la implementación de redes neuronales convolucionales especializadas como EEGNet. Estas arquitecturas permiten aplicar convoluciones espaciales y temporales simultáneas para descubrir representaciones complejas directamente en la señal nativa, con el potencial de rescatar patrones ocultos que escapan a los descriptores estadísticos tradicionales.